

# ДЕКЛАРАТИВНОЕ ПРОГРАММИРОВАНИЕ

---

Регулярные выражения

# Регулярные выражения

.	Любой одиночный символ
[abc]	Любой из указанных символов: a, b, c
[^abc]	Любой символ, кроме указанных: a, b, c
[a-z]	Любая буква в указанном диапазоне
[[:digit:]]	Любая цифра ([0-9])
[[:alpha:]]	Любая буква (латиница)
[[:alnum:]]	Любая буква или цифра
[[:space:]]	Любой пробельный символ
\	Экранирование специальных символов
^	Начало строки
\$	Конец строки
	Или <a href="https://regex101.com/">https://regex101.com/</a> (PCRE)

# Квантификаторы

- $*$  0 или более повторений
- $+$  1 или более повторений
- $?$  0 или 1 повторение
- $\{n\}$  Ровно  $n$  повторений
- $\{n, \}$   $n$  или более повторений
- $\{n, m\}$  От  $n$  до  $m$  повторений

# Контекст важен

$.^*$  — последовательность любых символов

$[.^*]$  — один символ  $.$  или  $^*$

$^no$  — строка, начинающаяся с  $no$

$[^no]$  — символ, который не является ни  $n$  ни  $o$

$A-Z$  — строка из трех символов  $A-Z$

$[A-Z]$  — один из символов  $A, B, C, \dots, X, Y$ , или  $Z$

# Еще примеры

- `^[a-zA-Z_][a-zA-Z_0-9]*$` -- имена переменных в Си
- `(2[0-3]|1[0-9]|0[0-9]):[0-5][0-9]` – время
- `<[hH][1-6]>` -- HTML-заголовки `<h1>` `<H1>` `<h2>` ...

# Упражнения

Напишите регулярные выражения для нахождения:

1. за символом **a** следует один или более символов **b**
2. дата в формате уууу-mm-dd, где у,m,d – любые цифры
3. слово (состоит только из букв латинского алфавита) длины не менее 3 символов и начинающееся на гласную букву
4. слово с заглавной буквы
5. слово, в котором есть перенос на другую строку

# Библиотеки Haskell

## Установка

- regex-posix
  - cabal update
  - cabal install regex-posix

- regex-pcre

см. инструкции в classroom

## Использование

```
import Text.Regex.Posix
```

=~

```
ghci> import Text.Regex.Posix
```

```
ghci> :t (=~)
```

```
(=~)
```

```
:: (RegexMaker Regex CompOption ExecOption source,  
    RegexContext Regex source1 target) =>  
    source1 -> source -> target
```

`((=~) :: text -> regex -> result)`



# Наличие вхождения

```
ghci> "abc" =~ "[a-c]*" :: Bool
```

```
True
```

```
ghci> "abcd" =~ "[a-c]*" :: Bool
```

```
True
```

```
ghci> "defg" =~ "[a-c]*" :: Bool
```

```
True
```

```
ghci> "defg" =~ "^[a-c]*$" :: Bool
```

```
False
```

```
ghci> "abcd" =~ "^[a-c]*$" :: Bool
```

```
False
```

```
ghci> "abc" =~ "^[a-c]*$" :: Bool
```

```
True
```

# Количество вхождений

```
ghci> "honorificabilitudinitatibus" =~ "a" :: Int
```

2

```
ghci> "honorificabilitudinitatibus" =~ "[aeiouy]" :: Int
```

13

```
ghci> "honorificabilitudinitatibus" =~ "[^aeiouy]" :: Int
```

14

```
ghci> "honorificabilitudinitatibus" =~ "[a-z]" :: Int
```

27

# Упражнение

Почему?

```
ghci> "very long long long text" =~ ".*" :: Int
```

2

# Первое вхождение

```
ghci> "A Skateboard is reduced 5% in price " =~ "[0-9]%" :: String  
"5%"
```

```
ghci> "A Skateboard is reduced 25% in price" =~ "[0-9]%" :: String  
"5%"
```

```
ghci> "A Skateboard is reduced 25% in price" =~ "[0-9]{1,2}%" :: String  
"25%"
```

# Интервал (начало, длина)

```
ghci> "contrariwise" =~ "wise" :: (Int, Int)
```

```
(8,4)
```

```
ghci> "contrariwise" =~ "WISE" :: (Int, Int)
```

```
(-1,0)
```

# (префикс, вхождение, постфикс)

```
ghci> "it's my own invention" =~ "own" :: (String, String, String)
("it's my ", "own", " invention")
```

```
ghci> "it's my own invention" =~ "OWN" :: (String, String, String)
("it's my own invention", "", "")
```

# Все вхождения

```
> getAllTextMatches$ "A Skateboard is reduced 25% in price" =~ "[a-zA-Z]+" :: [String]  
["A", "Skateboard", "is", "reduced", "in", "price"]
```

# Упражнение

Что не так?

```
import Text.Regex.Posix
```

```
isCorrectHaskellFile :: String -> Bool
```

```
isCorrectHaskellFile filename = filename =~ ".hs"
```



# Упражнение

Напишите функцию, которая проверяет, является ли строка приветствием (Начинается со слова Hi в любом регистре)

- Hi Alex how are you doing
- hI dave how are you doing
- Hi, Alex!
- Good by Alex
- hidden agenda

# Упражнения

- Проверить, является ли строка двоичным числом
  - 1011110 - да
  - 101018 - нет
  - hello – нет
- Проверить, является ли строка номером телефона в формате +7-xxx-xxx-xxxx (где x – любая цифра)
- Проверить, что строка начинается и заканчивается одним и тем же словом. Извлечь это слово.
  - **she** said no one is as lovely as **she** – да
  - ow, I don't know – нет

# <Упражнение>

Верните уникальные имена всех html-тегов в **файле**

**Текст:**

`<p>This <br> is a paragraph <br> with <br> line breaks</p>`

`<a href="https://www.wikipedia.org/">A link to Wikipedia!</a>`

`<p>Oh well, <span lang="fr">c'estla vie</span>, as they say in France.</p>`

**Теги:**

p, br, a, span

# </Упражнение>